

Universidade Estadual de Campinas

ME731 - Métodos em Análise Multivariada
Professor: Aluísio De Souza Pinheiro

Análise de Variância Multivariada (MANOVA) e Discriminante Canônica em Variedades de Trigo

Projeto 1: Aspectos Metodológicos de uma Técnica de Análise Multivariada ou Modelo Teórico

Autora: Amanda Rehder Cedro

IMECC - Instituto de Matemática, Estatística e Computação Científica
UNICAMP – Campinas – SP
Outubro de 2026

Sumário

1 Introdução **3**

2 Metodologia **4**

2.1 Modelo Implantado 4

2.1.1 Modelo e hipóteses 4

2.1.2 Decomposição das somas de quadrados e produtos cruzados 4

2.1.3 Razão de verossimilhanças e o Lambda de Wilks 4

2.1.4 Autovalores de $\mathbf{E}^{-1}\mathbf{H}$ e as quatro estatísticas 5

2.1.5 Distribuição e aproximações 5

2.1.6 Casos particulares e conexões 6

2.1.7 Contrastes e intervalos simultâneos 6

2.1.8 Pressupostos e diagnósticos 7

2.1.9 Tamanho de efeito, informação parcial e reamostragem 7

2.2 Procedimentos Computacionais e Estudo de Simulação 8

3 Resultados **8**

3.1 Descrição dos Dados 8

3.2 Análise Gráfica 10

3.3 Ajuste do Modelo 11

3.4 Análise do Modelo 12

3.4.1 Contrastes e distâncias entre variedades 12

3.4.2 Variáveis canônicas 13

3.4.3 Classificação 14

3.5 Diagnóstico do Modelo 15

3.5.1 Normalidade multivariada 15

3.5.2 Homogeneidade das covariâncias 16

3.5.3 Valores atípicos 16

3.5.4 Sensibilidade 18

3.5.5 Testes de permutação e bootstrap 18

3.5.6 Estudo de simulação 18

4 Discussão Crítica **20**

5 Conclusão **22**

Lista de Figuras

1 Distribuição de cada atributo por variedade. 10
2 Matriz de dispersão dos sete atributos (painéis abaixo da diagonal). 11
3 Variáveis canônicas, com elipses de 95% e centroides (×). 14
4 Gráfico quantil-quantil das distâncias de Mahalanobis dos resíduos agrupados (linha tracejada: quantil de 99,9%). 17
5 Gráficos quantil-quantil das distâncias robustas (MCD) por variedade, em escala logarítmica. 17
6 Erro tipo I ($\delta = 0$) e poder em função de δ, por cenário. 20

Lista de Tabelas

1 Média (desvio-padrão) por variedade, estatística F da ANOVA univariada (2 e 207 graus de liberdade; todos os $p < 2{,}2 \times 10^{-16}$) e fator de inflação da variância (VIF). 9
2 MANOVA de um fator: estatísticas e aproximações F. 11
3 Lambda parcial por variável (menor valor = mais informativa), com F de $(2; 201)$ graus de liberdade, nas escalas original e logarítmica. 12
4 Contrastes planejados (covariância agrupada dos três grupos); p ajustado por Holm. 13
5 Distância de Mahalanobis ao quadrado (D^2) entre as médias das variedades. 13
6 Diferenças de médias e intervalos simultâneos de 95% (T^2, Bonferroni nos três pares). 13
7 Coeficientes de estrutura dos dois eixos canônicos. 14
8 Matriz de confusão da LDA (validação cruzada *leave-one-out*); linhas: variedade verdadeira. 15
9 Acurácia por validação cruzada *leave-one-out*, com intervalo binomial exato de 95%. 15
10 Testes de Mardia por variedade, nas escalas original e logarítmica. 15
11 Teste de Shapiro-Wilk (p-valores) para cada variável nos resíduos agrupados da MANOVA. 16
12 Grãos sinalizados por grupo: distância clássica e MCD (cobertura de 75%), e número de condição da matriz de correlação. 17
13 Sensibilidade das estatísticas de Wilks (Λ) e Pillai (V) e do tamanho de efeito. 18
14 Erro tipo I estimado (nível nominal 0,05; 1000 repetições; erro padrão $\approx 0{,}007$). 19
15 Poder estimado (1000 repetições por célula); δ é a fração do efeito observado. 19

1 Introdução

Em muitos problemas aplicados mede-se, em cada unidade amostral, um vetor de p características correlacionadas, e deseja-se saber se esses vetores diferem entre grupos. Aplicar p análises de variância univariadas separadas ignora a correlação entre as variáveis, infla a probabilidade global de erro tipo I e pode deixar de detectar diferenças que só existem em combinações das variáveis. A Análise de Variância Multivariada (MANOVA) trata o problema de forma conjunta, testando a igualdade dos vetores de médias em um único procedimento [1, 3, 2].

Este trabalho é organizado da seguinte forma:

- Apresenta formalmente o modelo da MANOVA de um fator, as quatro estatísticas clássicas (Wilks, Pillai, Hotelling-Lawley e Roy), seus pressupostos e suas conexões com a distância de Mahalanobis, a correlação canônica e a análise discriminante (Seção 2).
- Avalia, com dados reais e com simulação, o quanto as conclusões dependem dos pressupostos (normalidade multivariada e homogeneidade das matrizes de covariância) e qual estatística é mais confiável nessas condições (Seções 3 e 4).
- Aplica a técnica a 210 grãos de trigo de três variedades, com diagnósticos, contrastes planejados, intervalos simultâneos, testes de permutação, bootstrap, variáveis canônicas, classificação e um estudo de Monte Carlo (Seção 3).

A pergunta aplicada é: *As variedades diferem no vetor médio de atributos geométricos? Em quais atributos e em que direções? Quão confiável é essa inferência, dado que os pressupostos clássicos não são plenamente satisfeitos?*

Os dados são os do banco *Seeds* [4, 5], descritos na Seção 3.1.

2 Metodologia

2.1 Modelo Implantado

2.1.1 Modelo e hipóteses

Sejam $\mathbf{y}_{ij} \in \mathbb{R}^p$, com $i = 1, \ldots, g$ e $j = 1, \ldots, n_i$, e $n = \sum_i n_i$. O modelo de um fator é

$$\mathbf{y}_{ij} = \boldsymbol{\mu} + \boldsymbol{\tau}_i + \boldsymbol{\varepsilon}_{ij}, \qquad \boldsymbol{\varepsilon}_{ij} \overset{iid}{\sim} N_p(\mathbf{0}, \boldsymbol{\Sigma}), \qquad \sum_i n_i \boldsymbol{\tau}_i = \mathbf{0}, \tag{1}$$

e a hipótese de interesse é $H_0 : \boldsymbol{\tau}_1 = \cdots = \boldsymbol{\tau}_g = \mathbf{0}$, isto é, todos os grupos têm o mesmo vetor de médias. Os pressupostos são:

(i) observações independentes;

(ii) normalidade multivariada dentro de cada grupo;

(iii) a mesma matriz $\boldsymbol{\Sigma}$ em todos os grupos.

2.1.2 Decomposição das somas de quadrados e produtos cruzados

Com $\bar{\mathbf{y}}_i$ a média do grupo i e $\bar{\mathbf{y}}$ a média geral, definem-se

$$\mathbf{H} = \sum_i n_i (\bar{\mathbf{y}}_i - \bar{\mathbf{y}})(\bar{\mathbf{y}}_i - \bar{\mathbf{y}})^\top, \qquad \mathbf{E} = \sum_{i,j} (\mathbf{y}_{ij} - \bar{\mathbf{y}}_i)(\mathbf{y}_{ij} - \bar{\mathbf{y}}_i)^\top, \qquad \mathbf{T} = \mathbf{H} + \mathbf{E}, \tag{2}$$

com $\nu_H = g - 1$ e $\nu_E = n - g$ graus de liberdade. A matriz $\mathbf{S}_p = \mathbf{E}/\nu_E$ é a covariância agrupada. A decomposição $\mathbf{T} = \mathbf{H} + \mathbf{E}$ é a generalização matricial da identidade soma de quadrados entre + dentro = total da ANOVA.

2.1.3 Razão de verossimilhanças e o Lambda de Wilks

Sob normalidade, a verossimilhança maximizada é proporcional a $|\hat{\boldsymbol{\Sigma}}|^{-n/2}$. Sob o modelo completo, $\hat{\boldsymbol{\Sigma}}_1 = \mathbf{E}/n$; sob H_0 (média única), $\hat{\boldsymbol{\Sigma}}_0 = \mathbf{T}/n$. Assim, a razão de verossimilhanças é

$$\frac{L_0}{L_1} = \left(\frac{|\mathbf{E}|}{|\mathbf{T}|} \right)^{n/2} = \Lambda^{n/2}, \qquad \Lambda = \frac{|\mathbf{E}|}{|\mathbf{E} + \mathbf{H}|}. \tag{3}$$

O Lambda de Wilks é uma razão de *variâncias generalizadas* (determinantes): quanto menor, mais a variabilidade entre grupos explica a variabilidade total.

Para $p = 1$, $\Lambda = \mathrm{SQ}_E/\mathrm{SQ}_T = 1/(1 + \mathrm{SQ}_H/\mathrm{SQ}_E)$, função monótona da estatística F da ANOVA. Pelo teorema de Wilks, $-2\ln(L_0/L_1) = -n \ln \Lambda$ é assintoticamente $\chi^2_{p\nu_H}$ sob H_0.

2.1.4 Autovalores de $\mathbf{E}^{-1}\mathbf{H}$ e as quatro estatísticas

Sejam $\lambda_1 \geq \cdots \geq \lambda_s > 0$, com $s = \min(p, \nu_H)$, os autovalores não nulos de $\mathbf{E}^{-1}\mathbf{H}$. Como $|\mathbf{T}|/|\mathbf{E}| = |\mathbf{I} + \mathbf{E}^{-1}\mathbf{H}| = \prod_i (1 + \lambda_i)$,

$$\begin{aligned} \Lambda &= \prod_{i=1}^{s} \frac{1}{1+\lambda_i}, & V &= \sum_{i=1}^{s} \frac{\lambda_i}{1+\lambda_i} = \operatorname{tr}\left[\mathbf{H}(\mathbf{H}+\mathbf{E})^{-1}\right], \\ U &= \sum_{i=1}^{s} \lambda_i = \operatorname{tr}(\mathbf{E}^{-1}\mathbf{H}), & \theta &= \lambda_1, \end{aligned} \tag{4}$$

que são as estatísticas de Wilks (Λ), Pillai (V), Hotelling-Lawley (U) e Roy (θ). As três primeiras combinam *todos* os autovalores (produto ou somas); Roy usa apenas o maior.

A estatística de Roy tem uma motivação própria, o **princípio da união-interseção**. Para um vetor $\mathbf{a} \neq \mathbf{0}$, a variável projetada $\mathbf{a}^\top \mathbf{y}$ pode ser submetida a uma ANOVA univariada, com

$$F(\mathbf{a}) = \frac{\mathbf{a}^\top \mathbf{H}\mathbf{a}/\nu_H}{\mathbf{a}^\top \mathbf{E}\mathbf{a}/\nu_E}. \tag{5}$$

A hipótese H_0 é verdadeira se e somente se vale para todas as projeções, e rejeita-se quando $\max_{\mathbf{a}} F(\mathbf{a})$ é grande. Maximizar $\mathbf{a}^\top \mathbf{H}\mathbf{a}$ sob $\mathbf{a}^\top \mathbf{E}\mathbf{a} = 1$ leva, pelo método dos multiplicadores de Lagrange, a $\mathbf{H}\mathbf{a} = \lambda \mathbf{E}\mathbf{a}$, isto é, $\mathbf{E}^{-1}\mathbf{H}\mathbf{a} = \lambda \mathbf{a}$, e o máximo é λ_1, atingido no primeiro autovetor.

Roy é, portanto, a estatística mais poderosa quando a diferença entre grupos se concentra em *uma única* direção, e tende a ser menos poderosa quando duas ou mais direções contribuem.

2.1.5 Distribuição e aproximações

Sob H_0 e normalidade, $\mathbf{E} \sim W_p(\nu_E, \mathbf{\Sigma})$ e $\mathbf{H} \sim W_p(\nu_H, \mathbf{\Sigma})$ são independentes (distribuições de Wishart), e Λ tem a distribuição de Wilks $\Lambda(p, \nu_H, \nu_E)$, que coincide com a de um produto de variáveis Beta independentes. Na prática usam-se aproximações:

- **Bartlett**: $-\left[\nu_E - \frac{p-\nu_H+1}{2}\right] \ln \Lambda \approx \chi^2_{p\nu_H}$, uma correção do fator n do teorema de Wilks que melhora a aproximação em amostras finitas.
- **Rao (F para Wilks):** com $t = \sqrt{(p^2\nu_H^2 - 4)/(p^2 + \nu_H^2 - 5)}$ (e $t = 1$ se o denominador for nulo),

$$F = \frac{1 - \Lambda^{1/t}}{\Lambda^{1/t}} \cdot \frac{df_2}{df_1}, \quad df_1 = p\nu_H, \quad df_2 = wt - \tfrac{p\nu_H - 2}{2}, \quad w = \nu_E + \nu_H - \tfrac{p+\nu_H+1}{2}.$$

- **Pillai:** com $m = (|p - \nu_H| - 1)/2$ e $\nu^* = (\nu_E - p - 1)/2$,

$$F = \frac{2\nu^* + s + 1}{2m + s + 1} \cdot \frac{V}{s - V}, \quad \text{com } s(2m+s+1) \text{ e } s(2\nu^*+s+1) \text{ graus de liberdade.}$$

- **Roy:** $F = \lambda_1\, df_2/df_1$ com $df_1 = \max(p, \nu_H)$ e $df_2 = \nu_E - df_1 + \nu_H$. Essa aproximação é um *limite superior* do F exato; logo, o p-valor resultante é um limite inferior, isto é, tende a ser liberal.

2.1.6 Casos particulares e conexões

Dois grupos, T^2 de Hotelling e distância de Mahalanobis. Com $g = 2$, $\mathbf{H} = \frac{n_1 n_2}{n}\mathbf{d}\mathbf{d}^\top$ com $\mathbf{d} = \bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2$ tem posto 1, e há um único autovalor, $\lambda_1 = \frac{n_1 n_2}{n}\mathbf{d}^\top\mathbf{E}^{-1}\mathbf{d} = T^2/\nu_E$. Logo $\Lambda = 1/(1 + T^2/\nu_E)$, em que

$$T^2 = \frac{n_1 n_2}{n_1 + n_2}\, D^2, \qquad D^2 = (\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2)^\top \mathbf{S}_p^{-1} (\bar{\mathbf{y}}_1 - \bar{\mathbf{y}}_2), \tag{6}$$

sendo D^2 a distância de Mahalanobis entre as médias, e $\frac{n-p-1}{p(n-2)}T^2 \sim F_{p,\,n-p-1}$ sob H_0. Para populações normais com mesma $\boldsymbol{\Sigma}$ e probabilidades a priori iguais, o erro de Bayes da classificação em dois grupos é $\Phi(-D/2)$, o que liga a separação multivariada ao desempenho de classificação.

Correlação canônica. Seja $\mathbf{Z}$ a matriz de $g-1$ indicadoras dos grupos. Os quadrados das correlações canônicas entre $\mathbf{Z}$ e $\mathbf{y}$ são os autovalores de $\mathbf{T}^{-1}\mathbf{H}$. Se $\mathbf{T}^{-1}\mathbf{H}\mathbf{v} = \theta\mathbf{v}$, então $\mathbf{H}\mathbf{v} = \theta(\mathbf{E}+\mathbf{H})\mathbf{v}$, ou seja, $\mathbf{E}^{-1}\mathbf{H}\mathbf{v} = \frac{\theta}{1-\theta}\mathbf{v}$. Assim $\lambda_i = \rho_i^2/(1-\rho_i^2)$, isto é,

$$\rho_i^2 = \frac{\lambda_i}{1+\lambda_i}, \qquad V = \sum_i \rho_i^2, \qquad \Lambda = \prod_i (1-\rho_i^2). \tag{7}$$

Variáveis canônicas e discriminante. Os autovetores generalizados $\mathbf{a}_i$ de $(\mathbf{H} - \lambda_i\mathbf{E})\mathbf{a} = \mathbf{0}$, normalizados por $\mathbf{a}_i^\top \mathbf{S}_p \mathbf{a}_i = 1$, definem as *variáveis canônicas* $\mathbf{a}_i^\top\mathbf{y}$, que são as direções discriminantes de Fisher. O número de eixos é no máximo s, e o teste de dimensionalidade de Bartlett avalia quantos são necessários: com $\Lambda_k = \prod_{i=k}^{s}(1+\lambda_i)^{-1}$,

$$-\left(n - 1 - \tfrac{p+g}{2}\right)\ln\Lambda_k \approx \chi^2_{(p-k+1)(g-k)} \quad \text{sob } H_0^{(k)} : \text{apenas } k-1 \text{ eixos.} \tag{8}$$

2.1.7 Contrastes e intervalos simultâneos

Para um vetor de contrastes $\mathbf{c}$ ($\sum_i c_i = 0$), seja $\mathbf{L} = \sum_i c_i \bar{\mathbf{y}}_i$ e $f = \sum_i c_i^2/n_i$. Então

$$T_c^2 = \mathbf{L}^\top (f\,\mathbf{S}_p)^{-1}\mathbf{L}, \qquad \frac{\nu_E - p + 1}{p\,\nu_E}\, T_c^2 \sim F_{p,\,\nu_E - p+1} \quad \text{sob } H_0 :\ \textstyle\sum_i c_i \boldsymbol{\mu}_i = \mathbf{0}. \tag{9}$$

Intervalos simultâneos de confiança $1-\alpha$ para $\mathbf{a}^\top \sum_i c_i \boldsymbol{\mu}_i$, **válidos para todo $\mathbf{a}$** (em particular, para as p variáveis originais), são

$$\mathbf{a}^\top\mathbf{L} \pm \sqrt{c_\alpha\, f\, \mathbf{a}^\top \mathbf{S}_p \mathbf{a}}, \qquad c_\alpha = \frac{p\,\nu_E}{\nu_E - p + 1} F_{p,\nu_E-p+1;\alpha}. \tag{10}$$

Ao comparar m contrastes simultaneamente, usa-se α/m (Bonferroni).

2.1.8 Pressupostos e diagnósticos

Normalidade multivariada. Os testes de Mardia baseiam-se na assimetria e na curtose multivariadas,

$$b_{1,p} = \frac{1}{n^2}\sum_{i,j}\Big[(\mathbf{y}_i-\bar{\mathbf{y}})^\top \mathbf{S}_n^{-1}(\mathbf{y}_j-\bar{\mathbf{y}})\Big]^3, \qquad b_{2,p} = \frac{1}{n}\sum_{i}\Big[(\mathbf{y}_i-\bar{\mathbf{y}})^\top \mathbf{S}_n^{-1}(\mathbf{y}_i-\bar{\mathbf{y}})\Big]^2, \quad (11)$$

com $nb_{1,p}/6 \approx \chi^2_{p(p+1)(p+2)/6}$ e $\Big(b_{2,p} - p(p+2)\Big)/\sqrt{8p(p+2)/n} \approx N(0,1)$ sob normalidade.

Complementarmente, as distâncias de Mahalanobis ao quadrado, d_i^2, devem seguir aproximadamente χ^2_p (gráfico quantil-quantil). A versão robusta usa o estimador de determinante mínimo de covariância (MCD).

Homogeneidade das covariâncias. O teste M de Box usa $M = \nu_E \ln|\mathbf{S}_p| - \sum_i \nu_i \ln|\mathbf{S}_i|$, com $\nu_i = n_i - 1$, e $M(1-c) \approx \chi^2_{p(p+1)(g-1)/2}$, em que $c = \Big[\sum_i \nu_i^{-1} - \nu_E^{-1}\Big]\frac{2p^2+3p-1}{6(p+1)(g-1)}$. O teste é muito sensível à não normalidade.

Robustez. Estudos de simulação indicam que a estatística de Pillai é a mais robusta a violações dos pressupostos, que Roy é a mais sensível, e que tamanhos de grupo iguais atenuam o efeito da heterogeneidade das covariâncias.

2.1.9 Tamanho de efeito, informação parcial e reamostragem

Como o p-valor depende do tamanho amostral, reporta-se também o tamanho de efeito multivariado $\eta^2_{mult} = 1-\Lambda^{1/s}$ (e V/s). A contribuição de uma variável x_j *dadas as demais* é medida pelo Lambda parcial $\Lambda_j = \Lambda_p/\Lambda_{p-1}$, com

$$F = \frac{1-\Lambda_j}{\Lambda_j}\cdot\frac{\nu_E - p + 1}{\nu_H} \sim F_{\nu_H,\,\nu_E-p+1} \quad \text{sob } H_0. \quad (12)$$

Como alternativa aos testes paramétricos, o **teste de permutação** reatribui aleatoriamente os rótulos dos grupos e recalcula a estatística; o p-valor é $(1+\#\{T^* \geq T_{obs}\})/(B+1)$, cujo mínimo é $1/(B+1)$.

Ele pressupõe intercambiabilidade sob H_0 (em particular, covariâncias iguais) e, portanto, não elimina por completo o efeito da heterogeneidade. O **bootstrap estratificado** por grupo fornece intervalos percentílicos para η^2_{mult}.

Para múltiplas comparações usa-se a correção de Holm.

2.2 Procedimentos Computacionais e Estudo de Simulação

Todas as análises foram feitas em R (versão 4.2.2) com o pacote MASS. O gerador de números aleatórios é fixado (Mersenne-Twister, semente 731). Os testes de permutação usam $B = 2000$ permutações e o bootstrap, $B = 2000$ réplicas. O estudo de Monte Carlo usa $R = 1000$ repetições por célula, de modo que o erro padrão de uma taxa de rejeição próxima de 0,05 é de aproximadamente 0,007.

Os quatro cenários, todos com $g = 3$ e $p = 7$, são:

A : normal, covariâncias iguais, $n_i = 70$;

B : t multivariada com 5 graus de liberdade, covariâncias iguais, $n_i = 70$;

C : normal, covariâncias distintas e grupos desbalanceados, $n_i \in \{30, 70, 110\}$, com o menor grupo associado à maior covariância;

D : normal, covariâncias iguais às *estimadas* nos dados, $n_i = 70$, o cenário mais próximo do caso observado.

Nos cenários A e B usa-se a covariância agrupada dos dados. Em cada cenário, as médias populacionais são $\bar{\mathbf{y}} + \delta(\bar{\mathbf{y}}_i - \bar{\mathbf{y}})$, com $\delta \in \{0;\ 0{,}05;\ 0{,}075;\ 0{,}10\}$: $\delta = 0$ mede o erro tipo I e $\delta > 0$ mede o poder, em frações do efeito observado (a não centralidade cresce com δ^2).

Para Roy, além da aproximação F, calcula-se o poder com *tamanho corrigido*, usando como corte o quantil de 95% da distribuição de λ_1 simulada sob H_0 em cada cenário.

3 Resultados

3.1 Descrição dos Dados

O banco *Seeds* [4, 5] contém 210 grãos de trigo, 70 de cada variedade (Kama, Rosa e Canadian), medidos por raio-X. Os sete atributos são contínuos: **área** (A), **perímetro** (P), **compacidade** ($C = 4\pi A/P^2$), **comprimento** e **largura** do grão, **coeficiente de assimetria** e **comprimento do sulco**.

Não há valores ausentes. Os dados foram lidos diretamente de um repositório público do GitHub pelo próprio programa, que também confere a integridade (210 linhas, 70 por grupo e a média geral da área).

Atendem-se as exigências: $n = 210 \geq 30$, $p = 7 \geq 4$ e $n > p$. A variedade é o único fator discreto e serve de agrupamento. A compacidade é função não linear da área e do perímetro, o que será relevante para a multicolinearidade.

A Tabela 1 mostra que Rosa tem os maiores grãos em quase todas as dimensões, Canadian os menores, e Kama ocupa posição intermediária. A assimetria apresenta maior valor em Canadian, seguida por Rosa e, por fim, Kama. O comprimento do sulco separa Rosa das outras duas, e as ANOVAs univariadas rejeitam a igualdade das médias em todas as variáveis. Os desvios-padrão da área crescem com a média (coeficientes de variação de 8,5%, 7,9% e 6,1% para Kama, Rosa e Canadian), sugerindo heterogeneidade de variâncias de natureza multiplicativa.

Tabela 1: Média (desvio-padrão) por variedade, estatística F da ANOVA univariada (2 e 207 graus de liberdade; todos os $p < 2{,}2 \times 10^{-16}$) e fator de inflação da variância (VIF).

Variável	Kama	Rosa	Canadian	F	VIF
Área	14,334 (1,216)	18,334 (1,439)	11,874 (0,723)	548,19	701,6
Perímetro	14,294 (0,577)	16,136 (0,617)	13,248 (0,340)	541,58	599,3
Compacidade	0,880 (0,016)	0,884 (0,016)	0,849 (0,022)	75,87	18,6
Comprimento	5,508 (0,232)	6,148 (0,268)	5,230 (0,138)	322,19	49,2
Largura	3,245 (0,178)	3,677 (0,186)	2,854 (0,148)	406,30	106,9
Assimetria	2,667 (1,174)	3,645 (1,182)	4,788 (1,336)	51,89	1,4
Sulco	5,087 (0,264)	6,021 (0,254)	5,116 (0,162)	368,95	12,1

As variáveis são fortemente correlacionadas: área e perímetro ($r = 0{,}994$), área e largura (0,971), perímetro e comprimento (0,972) e comprimento e sulco (0,933). Os autovalores da matriz de correlação são 5,031; 1,198; 0,678; 0,068; 0,019; 0,005 e 0,0008, com número de condição de 6193. Os VIF (Tabela 1) chegam a 701,6 (área) e 599,3 (perímetro).

Há, portanto, multicolinearidade severa: os autovalores indicam que duas a três dimensões concentram quase toda a variabilidade dos sete atributos. Isso não impediu a inversão de $\mathbf{E}$ nem o cálculo das estatísticas, mas impede interpretar coeficientes individuais (Seção 3.4).

3.2 Análise Gráfica

A Figura 1 mostra a distribuição de cada atributo por variedade. As variáveis de tamanho (área, perímetro, comprimento, largura e sulco) separam Rosa das demais com pouca sobreposição; já a compacidade e a assimetria se sobrepõem bastante entre variedades, de modo que nenhuma variável isolada separa as três variedades sem sobreposição apreciável.

Há poucos pontos isolados, por exemplo grãos pequenos de Kama na área e valores altos de assimetria em Canadian e Kama.

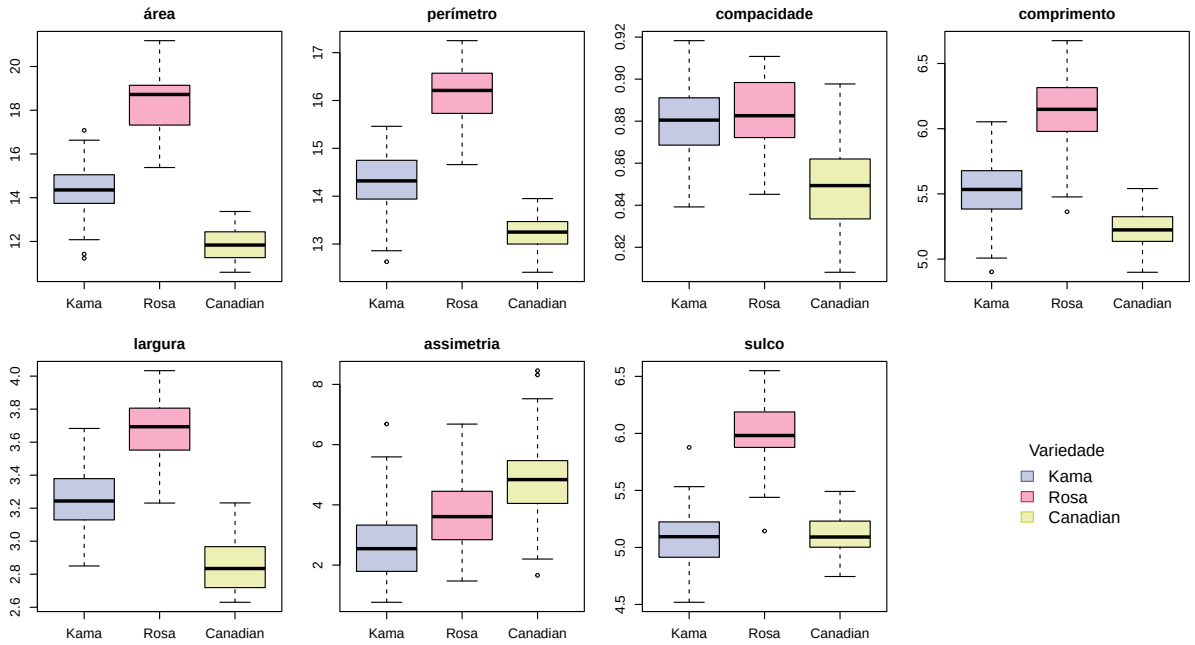


Figura 1: Distribuição de cada atributo por variedade.

A matriz de dispersão (Figura 2, apenas com os painéis abaixo da diagonal, pois os de cima são simétricos) mostra a relação quase linear entre área e perímetro, entre área e largura e entre comprimento e sulco, que corresponde às correlações de 0,93 a 0,99, e a relação curva entre a compacidade e o tamanho, coerente com $C = 4\pi A/P^2$. Os grupos formam nuvens distintas em quase todos os pares, com Kama no centro e a maior proximidade entre Kama e Canadian.

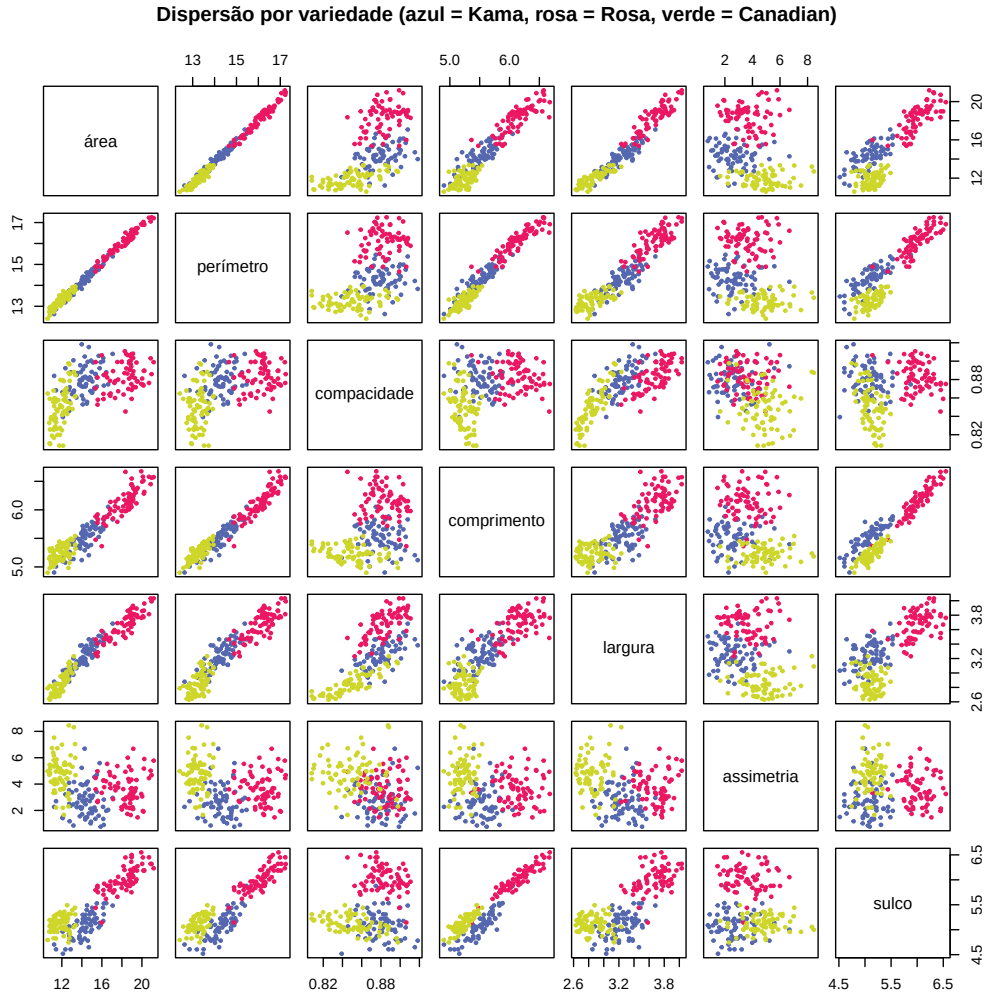


Figura 2: Matriz de dispersão dos sete atributos (painéis abaixo da diagonal).

3.3 Ajuste do Modelo

As quatro estatísticas rejeitam H_0 com folga (Tabela 2). Os autovalores de $\mathbf{E}^{-1}\mathbf{H}$ são $\lambda_1 = 6{,}2368$ e $\lambda_2 = 2{,}9159$, e os quadrados das correlações canônicas são $\rho_1^2 = 0{,}862$ e $\rho_2^2 = 0{,}745$. Confere-se a identidade (7): $\Lambda = (1-\rho_1^2)(1-\rho_2^2) = 0{,}0353$ e $V = \rho_1^2 + \rho_2^2 = 1{,}6065$. A aproximação de Rao é reproduzida à mão: $p = 7$, $\nu_H = 2$ e $t = 2$ dão $F = 124{,}14$ com $(14; 402)$ graus de liberdade, igual ao valor reportado.

Tabela 2: MANOVA de um fator: estatísticas e aproximações F.

Estatística	Valor	F aprox.	g.l.	p
Wilks (Λ)	0,03529	124,14	(14; 402)	$< 2{,}2 \times 10^{-16}$
Pillai (V)	1,6065	117,79	(14; 404)	$< 2{,}2 \times 10^{-16}$
Hotelling-Lawley (U)	9,1527	130,75	(14; 400)	$< 2{,}2 \times 10^{-16}$
Roy ($\theta = \lambda_1$)	6,2368	179,98	(7; 202)	$< 2{,}2 \times 10^{-16}$

O tamanho de efeito é muito grande: $\eta^2_{mult} = 1 - \Lambda^{1/2} = 0{,}812$ (intervalo bootstrap de 95%: 0,790 a 0,846) e $V/s = 0{,}803$. O teste de dimensionalidade de Bartlett (8) rejeita tanto "só 0 eixos" ($\chi^2 = 682{,}2$; 14 g.l.) quanto "só 1 eixo" ($\chi^2 = 278{,}5$; 6 g.l.), com $p < 2{,}2 \times 10^{-16}$ nos dois casos: a separação entre variedades é **bidimensional**, com o primeiro eixo respondendo por 68,1% e o segundo por 31,9% da separação.

Contribuição individual das variáveis. O Lambda parcial (12) (Tabela 3) mostra que, na escala original, todas as variáveis acrescentam informação dadas as demais, **exceto a largura** ($\Lambda_j = 0{,}9995$; $p = 0{,}950$), redundante, o que concorda com seu alto VIF; o sulco é a mais informativa ($\Lambda_j = 0{,}531$). A compacidade é informativa ($\Lambda_j = 0{,}854$) apesar de ser função da área e do perímetro, porque essa função é *não linear* e o modelo é linear nas variáveis originais. Na escala logarítmica o quadro muda: como $\ln C = \ln(4\pi) + \ln A - 2\ln P$ (a menos do arredondamento da compacidade em quatro casas), área, perímetro e compacidade tornam-se quase linearmente dependentes, de modo que cada uma é redundante dadas as outras duas ($p = 0{,}203$; 0,222 e 0,157). Essa não significância não indica ausência de informação, e sim colinearidade quase exata entre as três variáveis.

Tabela 3: Lambda parcial por variável (menor valor = mais informativa), com F de $(2; 201)$ graus de liberdade, nas escalas original e logarítmica.

	Escala original			Escala logarítmica		
Variável	Λ_j	F	p	Λ_j	F	p
Área	0,8609	16,24	$2{,}9 \times 10^{-7}$	0,9842	1,61	0,203
Perímetro	0,8400	19,15	$2{,}4 \times 10^{-8}$	0,9851	1,52	0,222
Compacidade	0,8535	17,24	$1{,}2 \times 10^{-7}$	0,9817	1,87	0,157
Comprimento	0,7642	31,01	$1{,}8 \times 10^{-12}$	0,7826	27,92	$2{,}0 \times 10^{-11}$
Largura	0,9995	0,05	0,950	0,9884	1,18	0,309
Assimetria	0,8862	12,90	$5{,}4 \times 10^{-6}$	0,8960	11,67	$1{,}6 \times 10^{-5}$
Sulco	0,5311	88,73	$< 2{,}2 \times 10^{-16}$	0,4810	108,46	$< 2{,}2 \times 10^{-16}$

3.4 Análise do Modelo

3.4.1 Contrastes e distâncias entre variedades

Todos os contrastes planejados são significativos (Tabela 4; $p < 2{,}2 \times 10^{-16}$ após Holm). As distâncias de Mahalanobis entre as médias (Tabela 5) são $D^2 = 27{,}42$ (Kama-Rosa), 18,39 (Kama-Canadian) e 35,39 (Rosa-Canadian), e a identidade (6) é reproduzida numericamente (959,73; 643,63 e 1238,56).

Kama e Canadian são as variedades mais próximas e Rosa e Canadian as mais distantes, o que antecipa onde ocorrerão os erros de classificação.

Tabela 4: Contrastes planejados (covariância agrupada dos três grupos); p ajustado por Holm.

Contraste	T^2	F (7; 201)	p (Holm)
Kama − Rosa	959,7	133,1	$< 2{,}2 \times 10^{-16}$
Kama − Canadian	643,6	89,3	$< 2{,}2 \times 10^{-16}$
Rosa − Canadian	1238,6	171,8	$< 2{,}2 \times 10^{-16}$
Canadian − média(Kama, Rosa)	934,9	129,7	$< 2{,}2 \times 10^{-16}$

Tabela 5: Distância de Mahalanobis ao quadrado (D^2) entre as médias das variedades.

	Kama	Rosa	Canadian
Kama	0	27,421	18,390
Rosa	27,421	0	35,388
Canadian	18,390	35,388	0

Os intervalos simultâneos de 95% para os três pares (10), com $\alpha = 0{,}05/3$ por par, indicam *em quais variáveis* as médias diferem (Tabela 6). Apenas dois intervalos contêm o zero: a **compacidade** entre Kama e Rosa ([−0,016; 0,010]) e o **sulco** entre Kama e Canadian ([−0,196; 0,137]).

Isso concorda com a Tabela 1 (compacidade 0,880 *vs.* 0,884; sulco 5,087 *vs.* 5,116) e explica por que cada par exige atributos diferentes para ser separado.

Tabela 6: Diferenças de médias e intervalos simultâneos de 95% (T^2, Bonferroni nos três pares).

Variável	Kama − Rosa	Kama − Canadian	Rosa − Canadian
Área	−4,000 [−4,839; −3,160]	2,461 [1,621; 3,300]	6,460 [5,621; 7,300]
Perímetro	−1,841 [−2,220; −1,463]	1,046 [0,668; 1,425]	2,888 [2,509; 3,267]
Compacidade	−0,003 [−0,016; 0,010]	0,031 [0,018; 0,044]	0,034 [0,021; 0,047]
Comprimento	−0,640 [−0,798; −0,482]	0,279 [0,120; 0,437]	0,919 [0,760; 1,077]
Largura	−0,433 [−0,556; −0,310]	0,391 [0,268; 0,514]	0,824 [0,700; 0,947]
Assimetria	−0,977 [−1,866; −0,089]	−2,121 [−3,009; −1,233]	−1,144 [−2,032; −0,255]
Sulco	−0,933 [−1,100; −0,767]	−0,029 [−0,196; 0,137]	0,904 [0,738; 1,071]

3.4.2 Variáveis canônicas

Os coeficientes de estrutura (correlações entre as variáveis e os eixos canônicos) estão na Tabela 7. O **primeiro eixo é um eixo de tamanho** (área, perímetro, comprimento, largura e sulco, com correlações de 0,92 a 0,98) e separa Rosa das demais; o **segundo é um eixo de forma**, dominado pela assimetria (−0,642) e pela compacidade (0,492), e separa Kama de Canadian (Figura 3).

Os coeficientes canônicos padronizados são instáveis (por exemplo, −0,494 para a área e +1,997 para o perímetro no primeiro eixo, e −4,888 e +4,471 no segundo), o que é típico de variáveis quase colineares; eles não devem ser interpretados individualmente, e a interpretação se apoia nos coeficientes de estrutura. O sinal dos eixos é arbitrário e foi ancorado de modo que o primeiro eixo correlacione positivamente com a área.

Tabela 7: Coeficientes de estrutura dos dois eixos canônicos.

Variável	CV1	CV2
Área	0,978	0,152
Perímetro	0,980	0,129
Compacidade	0,531	0,492
Comprimento	0,936	0,057
Largura	0,932	0,256
Assimetria	−0,177	−0,642
Sulco	0,917	−0,274

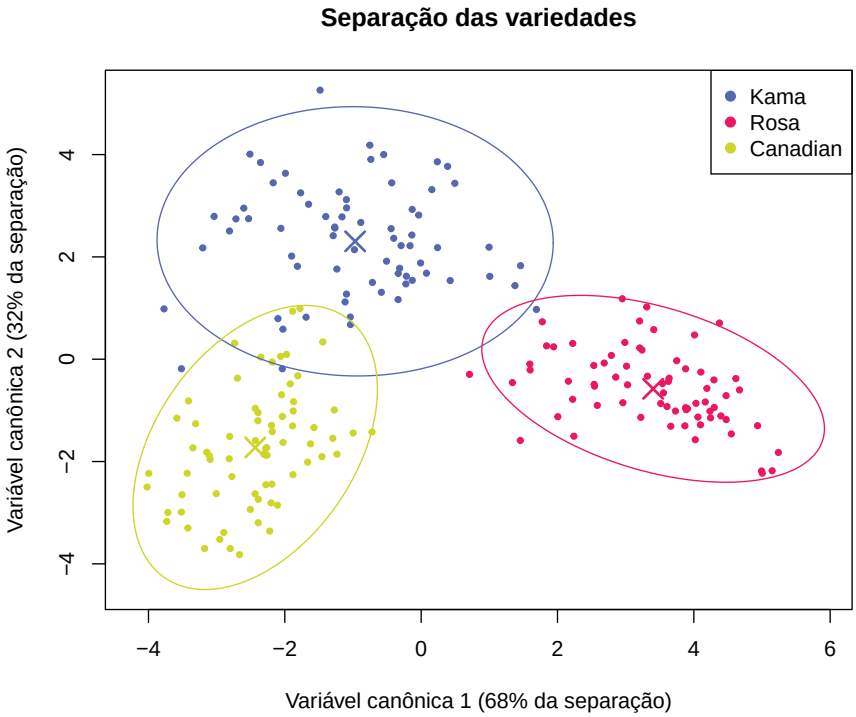


Figura 3: Variáveis canônicas, com elipses de 95% e centroides (×).

3.4.3 Classificação

A análise discriminante linear (LDA), avaliada por validação cruzada *leave-one-out*, acerta 203 dos 210 grãos (Tabela 9). A QDA acerta 199 e a LDA na escala logarítmica, 204; a diferença entre as duas LDA equivale a **um único grão**, e os intervalos se sobrepõem amplamente. A matriz de confusão (Tabela 8) mostra que os 7 erros da LDA são 3 grãos de Kama classificados como Canadian, 3 de Canadian como Kama e 1 de Kama como Rosa; Rosa é classificada corretamente em 70 de 70. Isso coincide com as distâncias da seção anterior.

O erro de Bayes teórico por par, $\Phi(-D/2)$, é 0,44% (Kama-Rosa), 1,60% (Kama-Canadian) e 0,15% (Rosa-Canadian). Os erros observados por par (1, 6 e 0 em 140 grãos,

ou 0,7%, 4,3% e 0%) mantêm a mesma ordem, mas o observado é maior no par Kama-Canadian, como esperado: o erro de Bayes calculado com a distância *estimada* é otimista, e há custo de estimação e desvios da normalidade.

Tabela 8: Matriz de confusão da LDA (validação cruzada *leave-one-out*); linhas: variedade verdadeira.

	Kama	Rosa	Canadian
Kama	66	1	3
Rosa	0	70	0
Canadian	3	0	67

Tabela 9: Acurácia por validação cruzada *leave-one-out*, com intervalo binomial exato de 95%.

Método	Acertos	Erros	Acurácia	IC de 95%
LDA	203	7	96,67%	[93,25%; 98,65%]
QDA	199	11	94,76%	[90,82%; 97,36%]
LDA (escala log)	204	6	97,14%	[93,89%; 98,94%]

3.5 Diagnóstico do Modelo

3.5.1 Normalidade multivariada

A Tabela 10 mostra que a assimetria multivariada de Mardia rejeita a normalidade nos três grupos (84 graus de liberdade, $p(p+1)(p+2)/6$), enquanto a curtose rejeita apenas em Kama ($z = 6{,}55$). Na escala logarítmica, Rosa e Canadian deixam de rejeitar, mas Kama continua rejeitando.

Os testes de Shapiro-Wilk univariados nos resíduos (Tabela 11) não rejeitam nenhuma variável após a correção de Bonferroni ($0{,}05/7 \approx 0{,}007$; o menor p é 0,033, em assimetria). A não normalidade é, portanto, essencialmente *conjunta*, concentrada em Kama.

Tabela 10: Testes de Mardia por variedade, nas escalas original e logarítmica.

Variedade	Escala	Assimetria	p	Curtose z	p
Kama	original	294,89	$< 0{,}0001$	6,55	$< 0{,}0001$
Kama	log	213,58	$< 0{,}0001$	5,04	$< 0{,}0001$
Rosa	original	143,19	0,0001	0,51	0,609
Rosa	log	67,84	0,901	$-1{,}61$	0,107
Canadian	original	135,75	0,0003	0,57	0,566
Canadian	log	96,83	0,160	$-0{,}22$	0,825

Tabela 11: Teste de Shapiro-Wilk (p-valores) para cada variável nos resíduos agrupados da MANOVA.

	Área	Perím.	Compac.	Compr.	Larg.	Assim.	Sulco
p-valor	0,0405	0,0690	0,8097	0,1926	0,5307	0,0334	0,2418

3.5.2 Homogeneidade das covariâncias

O teste M de Box rejeita a igualdade ($M = 707{,}7$; $\chi^2 = 674{,}1$; 56 g.l.; $p < 0{,}0001$). Na escala logarítmica a estatística cai para $\chi^2 = 152{,}7$ (redução de 77%), embora ainda rejeite, o que confirma que a heterogeneidade é em grande parte multiplicativa.

Como o teste é sensível à não normalidade, a rejeição deve ser lida junto com os resultados da simulação (Seção 3.5.6).

3.5.3 Valores atípicos

A distância de Mahalanobis clássica dos resíduos agrupados tem um único ponto acima do quantil de 99,9% do χ^2_7 (24,3): o grão da linha 60 (Kama), com $d^2 = 42{,}2$ (Figura 4).

Por grupo, a distância clássica ultrapassa o quantil de 97,5% em apenas 3, 2 e 3 grãos (Kama, Rosa e Canadian), compatível com o esperado (Tabela 12).

Já o MCD (com cobertura de 75%) sinaliza 11, 15 e 12 grãos, o que **não deve ser lido como valores atípicos**: o número de condição da correlação robusta (13.003; 37.372; 38.294) é maior que o da clássica (7.233; 13.143; 17.557), isto é, o estimador robusto, ao descartar pontos, fica ainda mais próximo da singularidade num conjunto de variáveis quase colineares, e as distâncias se inflam (Figura 5).

O grão mais discrepante é o da linha 60 pela distância clássica; o MCD também aponta, em Kama, as linhas 60, 62, 38, 61 e 24 como as mais afastadas.

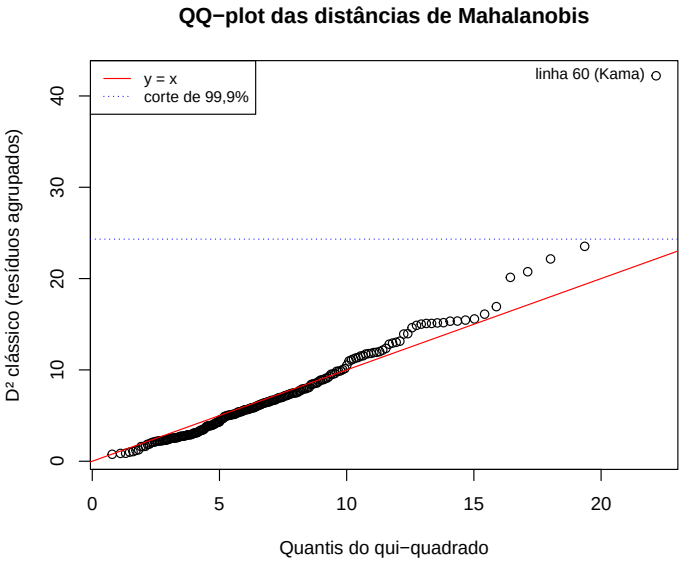


Figura 4: Gráfico quantil-quantil das distâncias de Mahalanobis dos resíduos agrupados (linha tracejada: quantil de 99,9%).

Tabela 12: Grãos sinalizados por grupo: distância clássica e MCD (cobertura de 75%), e número de condição da matriz de correlação.

	Grãos sinalizados			Cond. da correlação	
Variedade	Clássica ($> q_{97,5}$)	MCD ($> q_{97,5}$)	MCD ($> q_{99,9}$)	Clássica	Robusta
Kama	3	11	7	7.233	13.003
Rosa	2	15	14	13.143	37.372
Canadian	3	12	9	17.557	38.294

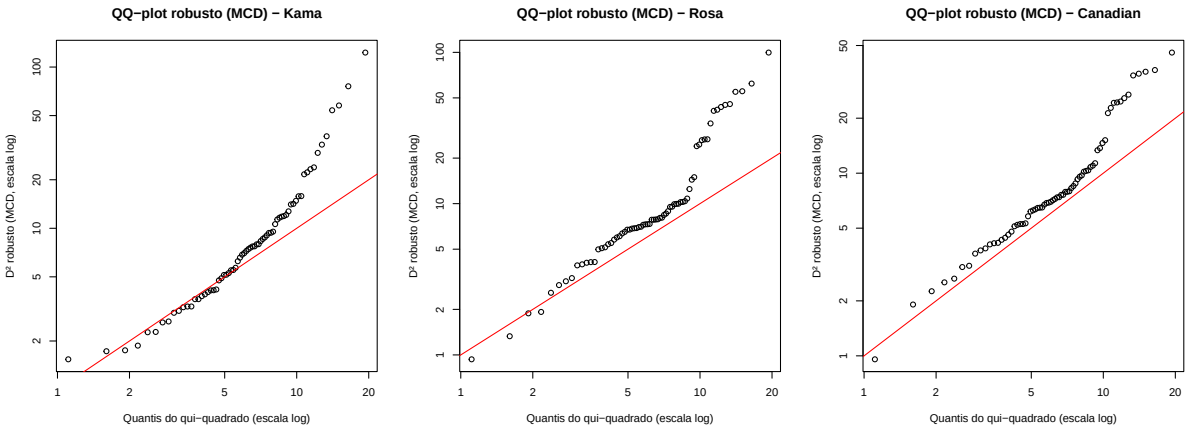


Figura 5: Gráficos quantil-quantil das distâncias robustas (MCD) por variedade, em escala logarítmica.

3.5.4 Sensibilidade

A Tabela 13 compara a análise original com duas variantes.

(i) Na escala logarítmica, os valores são praticamente os mesmos.

(ii) Removendo os três grãos mais discrepantes de Kama (linhas 60 a 62, escolhidos após a inspeção dos diagnósticos e, portanto, como análise de sensibilidade e não como exclusão), a separação fica ainda mais forte;

o M de Box continua rejeitando ($\chi^2 = 684{,}5$) e a curtose de Kama passa de $z = 6{,}55$ para $z = 2{,}19$ ($p = 0{,}028$), mas a assimetria segue significativa. A conclusão não depende desses grãos.

Tabela 13: Sensibilidade das estatísticas de Wilks (Λ) e Pillai (V) e do tamanho de efeito.

Análise	Λ	V	η^2_{mult}
Original	0,0353	1,6065	0,8122
Escala logarítmica	0,0422	1,5606	0,7946
Sem as linhas 60 a 62 (Kama)	0,0314	1,6254	0,8228

3.5.5 Testes de permutação e bootstrap

Com $B = 2000$, as quatro estatísticas têm $p = 0{,}0005 = 1/(B + 1)$, o menor valor atingível: nenhuma permutação igualou o valor observado, de modo que o resultado deve ser descrito como $p < 0{,}0005$.

Para os pares (com T^2 de duas amostras e a covariância do próprio par, o que explica valores diferentes dos da Tabela 4), obtêm-se $T^2 = 780{,}7$ (Kama-Rosa), 523,3 (Kama-Canadian) e 1684,2 (Rosa-Canadian), todos com $p = 0{,}0005$ e 0,0015 após Holm.

O teste de permutação concorda, portanto, com os testes paramétricos, e a concordância é esperada dado o tamanho do efeito. O bootstrap estratificado fornece o intervalo de 95% de 0,790 a 0,846 para η^2_{mult}.

3.5.6 Estudo de simulação

A Tabela 14 mostra o erro tipo I. Em condições ideais (cenário A), Pillai, Wilks e Hotelling-Lawley ficam próximos do nível nominal (0,047 cada) e, sob a t multivariada (B), são levemente conservadores (0,041 a 0,042).

Com covariâncias distintas e grupos desbalanceados (C), o erro tipo I dobra, para cerca de 0,099. No cenário D, o mais próximo dos dados observados, há inflação moderada, de 0,065 a 0,068 (entre 2 e 3 erros padrão acima de 0,05).

Roy pela aproximação F tem erro tipo I inflado em todos os cenários (0,150 a 0,255). A calibração diretamente na distribuição nula do cenário A confirma isso: o corte de λ_1 implícito na aproximação F é 0,0712, contra 0,0925 do quantil de 95% simulado, e o nível real da regra é 16,3%.

Tabela 14: Erro tipo I estimado (nível nominal 0,05; 1000 repetições; erro padrão ≈ 0,007).

Cenário	Pillai	Wilks	Hotelling-Lawley	Roy (aprox. F)
A: normal, cov. iguais	0,047	0,047	0,047	0,150
B: t(5), cov. iguais	0,041	0,042	0,041	0,158
C: cov. distintas, desbalanceado	0,099	0,099	0,098	0,255
D: cov. reais, balanceado	0,065	0,068	0,068	0,171

O poder (Tabela 15 e Figura 6) é praticamente idêntico para Pillai, Wilks e Hotelling-Lawley.

O poder "aparente" de Roy pela aproximação F é maior, mas é um artefato do nível inflado; com o **tamanho corrigido** (corte da distribuição nula simulada em cada cenário), Roy é, em geral, **menos poderoso** que as demais (por exemplo, $\delta = 0{,}10$: 0,704 contra 0,752 em A e 0,659 contra 0,771 em D); a única exceção é um empate técnico em B com $\delta = 0{,}05$ (0,193 contra 0,192).

Isto é coerente com a teoria (Seção 2.1.4): aqui a separação é bidimensional ($\lambda_2/\lambda_1 = 0{,}47$) e Roy só captura a primeira direção. Nos cenários com nível inflado (C), os poderes das demais estatísticas não são diretamente comparáveis com os de A, B e D.

Como o efeito observado corresponde a $\delta = 1$, com não centralidade 100 vezes a de $\delta = 0{,}10$, a inflação do erro tipo I observada nos cenários C e D é desprezível diante da evidência: o poder já é de cerca de 77% em $\delta = 0{,}10$.

Tabela 15: Poder estimado (1000 repetições por célula); δ é a fração do efeito observado.

Cenário	δ	Pillai	Wilks	Hotelling-Lawley	Roy (aprox. F)	Roy (corrigido)
A	0,05	0,204	0,207	0,208	0,396	0,199
A	0,075	0,488	0,489	0,493	0,661	0,436
A	0,10	0,752	0,753	0,754	0,871	0,704
B	0,05	0,192	0,193	0,196	0,381	0,193
B	0,075	0,517	0,518	0,519	0,686	0,473
B	0,10	0,832	0,831	0,832	0,917	0,759
C	0,05	0,306	0,308	0,310	0,490	0,197
C	0,075	0,566	0,571	0,573	0,773	0,446
C	0,10	0,840	0,845	0,848	0,945	0,777
D	0,05	0,242	0,249	0,249	0,426	0,193
D	0,075	0,490	0,493	0,496	0,676	0,403
D	0,10	0,771	0,773	0,772	0,873	0,659

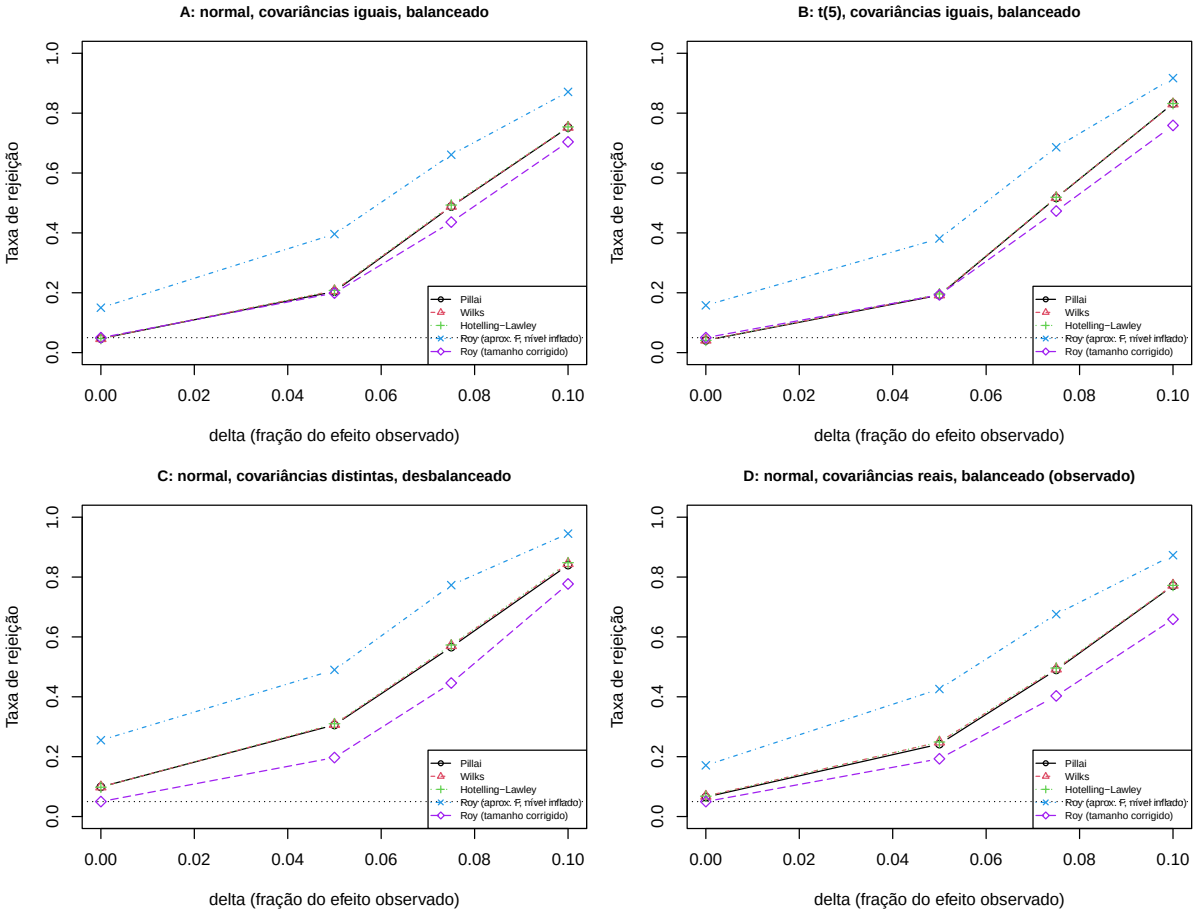


Figura 6: Erro tipo I ($\delta = 0$) e poder em função de δ, por cenário.

4 Discussão Crítica

Vantagens:

- Trata as variáveis conjuntamente, usando a estrutura de correlação, e produz um único teste global com controle do erro tipo I, seguido por contrastes e intervalos simultâneos que localizam as diferenças.
- Nenhuma variável isolada separa as três variedades sem sobreposição apreciável (assimetria e compacidade se sobrepõem, Figura 1), mas a combinação linear certa separa quase perfeitamente (Figura 3).
- Conecta-se naturalmente com a distância de Mahalanobis, a análise canônica e a discriminante, o que permite interpretar a diferença (tamanho e forma) e prever o desempenho de classificação.
- Permite avaliar o tamanho do efeito ($\eta^2_{mult} \approx 0{,}81$), e não apenas a significância: com $p < 0{,}0005$ em todos os testes, o interesse está em descrever a estrutura da diferença (duas dimensões; Kama e Canadian como as mais próximas).

Desvantagens:

- Depende de pressupostos fortes (normalidade multivariada e covariâncias iguais), que são violados nestes dados (Mardia e Box).
- As quatro estatísticas não são equivalentes quando $s > 1$ e podem divergir; a aproximação F de Roy mostrou-se inadequada, com erro tipo I de 0,15 a 0,255.
- O erro tipo I fica inflado com covariâncias distintas (C: $\approx 0{,}10$; D: $\approx 0{,}07$).
- A multicolinearidade (VIF até 702) não prejudica o teste global, mas torna instáveis os coeficientes canônicos padronizados e confunde as contribuições parciais; a compacidade foi informativa na escala original (pela não linearidade) e redundante na escala logarítmica (por colinearidade quase exata).

Limitações:

- *Independência:* os grãos foram medidos em campos experimentais cujo registro não consta do banco, e um possível efeito de lote ou campo não pode ser modelado. Os grãos mais discrepantes de Kama (linhas 60 a 62) são consecutivos no arquivo, o que *sugere*, sem comprovar, algum agrupamento; esse ponto não foi testado.
- Apenas três grupos, o que limita a dimensão a dois eixos.
- O MCD é pouco informativo com variáveis quase colineares; a detecção de atípicos baseou-se na distância clássica.
- A permutação de rótulos pressupõe intercambiabilidade (covariâncias iguais) e, portanto, não elimina totalmente o efeito da heterogeneidade.
- A remoção das linhas 60 a 62 foi escolhida *a posteriori* e serve apenas como sensibilidade.
- O estudo de simulação considera cenários paramétricos específicos, e os resultados não se estendem automaticamente a outras configurações.

Melhorias:

- Testes robustos de MANOVA baseados em estimadores robustos de localização e dispersão, com regularização dada a colinearidade.
- Testes não paramétricos multivariados por postos.
- Redução de dimensão (componentes principais) antes da análise, que elimina a colinearidade, e análise discriminante regularizada, que interpola entre LDA e QDA.
- Transformações de Box-Cox ou Yeo-Johnson ajustadas por grupo.

- Se houvesse registro de campo ou lote, modelos mistos multivariados com efeito aleatório de lote.
- Uma análise com menos variáveis (por exemplo, sem a largura, cujo Lambda parcial é 0,9995), que perderia pouca informação.

Os resultados recomendam **Pillai** (ou Wilks) como estatística de referência e desaconselham o uso de Roy pela aproximação F. Com tamanhos de grupo iguais ($n_i = 70$), o efeito prático das violações é moderado, e a evidência é tão forte que as conclusões não dependem delas.

5 Conclusão

Este trabalho investigou se três variedades de trigo (Kama, Rosa e Canadian) diferem em relação a sete atributos medidos por raio-X, utilizando a Análise de Variância Multivariada (MANOVA) como base central. A motivação metodológica residiu na insuficiência de análises univariadas separadas, que ignoram a estrutura de correlação entre as variáveis, inflam a probabilidade de erro tipo I e podem negligenciar diferenças que se manifestam apenas em combinações lineares dos atributos.

Do ponto de vista metodológico, apresentou-se formalmente o modelo de MANOVA de um fator, incluindo a decomposição das somas de quadrados e produtos cruzados, a razão de verossimilhanças e o Lambda de Wilks, os autovalores de $\mathbf{E}^{-1}\mathbf{H}$ e as quatro estatísticas clássicas (Wilks, Pillai, Hotelling-Lawley e Roy), com suas distribuições e aproximações. Estabeleceram-se, ainda, as conexões da MANOVA com a distância de Mahalanobis, a correlação canônica e a análise discriminante, bem como os procedimentos de contrastes planejados, intervalos simultâneos e diagnósticos de pressupostos.

Os resultados revelaram diferenças extremamente significativas entre as variedades no vetor médio de atributos ($\Lambda = 0,035$; $V = 1,606$; $\eta^2_{\text{mult}} = 0,812$; todos os $p < 2,2\times10^{-16}$). A separação mostrou-se bidimensional: o primeiro eixo canônico (68,1% da separação) é um eixo de tamanho, dominado por área, perímetro, comprimento, largura e sulco, que distingue Rosa das demais variedades; o segundo eixo (31,9%) é um eixo de forma, associado à assimetria e à compacidade, que separa Kama de Canadian. As distâncias de Mahalanobis entre as médias ($D^2 = 27,42$ entre Kama e Rosa; $18,39$ entre Kama e Canadian; $35,39$ entre Rosa e Canadian) confirmam que Kama e Canadian são as variedades mais próximas.

A análise discriminante linear, validada por *leave-one-out*, alcançou $96,7\%$ de acurácia (203/210), com apenas sete erros concentrados nos pares Kama-Canadian e Kama-Rosa, o que é consistente com as distâncias estimadas. A transformação logarítmica e a remoção dos grãos mais discrepantes não alteraram substancialmente as conclusões, e os testes de permutação ($p = 0,0005$) corroboraram os resultados paramétricos. O bootstrap forneceu intervalo de 95% para η^2_{mult} de $[0,790; 0,846]$, reforçando a magnitude do efeito.

Os diagnósticos revelaram violações dos pressupostos clássicos: não normalidade multivariada (especialmente em Kama, pela assimetria e curtose de Mardia) e heterogeneidade

das matrizes de covariância (teste M de Box, $p < 0,0001$), em grande parte de natureza multiplicativa, como indicou a redução de 77% na estatística após transformação logarítmica.

O estudo de simulação mostrou que, sob condições ideais (cenário A), Pillai, Wilks e Hotelling-Lawley mantêm o erro tipo I próximo do nominal ($\approx 0,047$), enquanto a aproximação F de Roy é liberal ($0,150$). Com covariâncias distintas e grupos desbalanceados (cenário C), o erro tipo I das três primeiras estatísticas dobra para cerca de $0,10$, e, no cenário mais próximo dos dados reais (D), há inflação moderada ($0,065$–$0,068$). O poder das três estatísticas é praticamente idêntico; Roy, quando corrigido pelo tamanho, tende a ser menos poderoso em situações de separação bidimensional, como a observada.

Diante desse panorama, recomenda-se a estatística de Pillai (ou, equivalentemente, Wilks) como referência para a MANOVA, especialmente quando os pressupostos não são plenamente satisfeitos. A aproximação F de Roy mostrou-se inadequada, com erro tipo I de 15% a $25,5$%, e não deve ser utilizada sem calibração adequada.

As principais limitações do estudo incluem a ausência de informação sobre possíveis efeitos de lote ou campo experimental, a natureza *a posteriori* da identificação dos grãos mais discrepantes (linhas 60–62 de Kama), a instabilidade dos coeficientes canônicos padronizados devido à multicolinearidade severa (VIF de até $701,6$) e a especificidade dos cenários de simulação. Como melhorias, sugerem-se testes robustos de MANOVA com estimadores regularizados, métodos não paramétricos multivariados, redução de dimensionalidade prévia (componentes principais) e análise discriminante regularizada.

Em síntese, a MANOVA mostrou-se uma ferramenta poderosa e informativa para o problema em questão, permitindo não apenas rejeitar a igualdade dos vetores médios com forte evidência, mas também descrever a estrutura da diferença em termos de direções canônicas interpretáveis (tamanho e forma), quantificar a separação entre grupos e prever o desempenho de classificação. A conclusão é robusta a transformações, exclusões e métodos de reamostragem, ainda que os pressupostos clássicos não sejam plenamente atendidos. O trabalho contribui, assim, tanto para a aplicação prática da MANOVA em dados de sementes quanto para a discussão metodológica sobre a escolha da estatística de teste e a importância dos diagnósticos em análises multivariadas.

Referências

[1] Johnson, R. A. & Wichern, D. W. *Applied Multivariate Statistical Analysis*, Sexta Edição. Pearson Education Limited, Nova Jersey, 2007.

[2] Koch, I. *Analysis of Multivariate and High-Dimensional Data: Theory and Practice*. Cambridge University Press, Nova Iorque, 2014.

[3] Mardia, K. V., Kent, J. T. & Bibby, J. M. *Multivariate Analysis*, Sétima Reimpressão. Academic Press, Londres, 2000.

[4] Charytanowicz, M., Niewczas, J., Kulczycki, P., Kowalski, P. A., Łukasik, S. & Żak, S. *Seeds*. UCI Machine Learning Repository, 2012. Disponível em: `https://archive.ics.uci.edu/dataset/236/seeds`.

[5] Charytanowicz, M., Niewczas, J., Kulczycki, P., Kowalski, P. A., Łukasik, S. & Żak, S. Complete gradient clustering algorithm for features analysis of X-ray images. Em *Information Technologies in Biomedicine*, Springer, 2010, pp. 15–24.